

Minería de Datos - Libro 1 - Clase 1 a 10

7. Repaso

Clase N° 7: Repaso de Conceptos

1. Presentación

A lo largo de las sesiones anteriores, hemos recorrido los conceptos fundamentales de la Minería de Datos, desde qué es y para qué sirve hasta las primeras técnicas de preparación y análisis exploratorio de datos, así como la introducción a técnicas de modelado como el clustering y la visualización.

El objetivo de esta clase es consolidar los conocimientos adquiridos, revisar los flujos de trabajo típicos en un proyecto de minería de datos y repasar las herramientas básicas y técnicas iniciales.

En esta clase, repasaremos:

- Los conceptos de Minería de Datos, su relación con otras disciplinas y sus aplicaciones.
- El proceso de descubrimiento de conocimiento (KDD) y el modelo CRISP-DM.
- Las técnicas esenciales de preparación de datos, incluyendo limpieza y transformación.
- El análisis exploratorio de datos (EDA) en sus modalidades univariada y multivariada.
- Las técnicas básicas de visualización de datos y sus herramientas.
- El concepto de Clustering y reducción de dimensionalidad (PCA).

Desarrollo

Conceptos Fundamentales de Minería de Datos

La minería de datos es una disciplina que se enfoca en el descubrimiento de patrones, tendencias y correlaciones dentro de grandes volúmenes de datos. Utiliza técnicas de diversas áreas como la Estadística, el Aprendizaje Automático, Bases de Datos y la Inteligencia Artificial.

Es importante diferenciar entre **Dato**, **Información** y **Conocimiento**:

Concepto	Definición	Ejemplo
Dato	Unidad mínima de información sin contexto.	"25°C"
Información	Dato procesado con significado.	"La temperatura actual es de 25°C"
Conocimiento	Interpretación de la información para la toma de decisiones.	"Dado que hace calor, la venta de bebidas frías aumentará"

Los proyectos de minería de datos suelen seguir metodologías estructuradas:

Proceso KDD (Knowledge Discovery in Databases) — 5 fases:

1. **Selección de datos:** Elegir los datos relevantes.
2. **Preprocesamiento y limpieza:** Manejar errores, duplicados, inconsistencias y valores faltantes.
3. **Transformación de datos:** Convertir datos a un formato adecuado para el análisis.
4. **Minería de datos:** Aplicar algoritmos para encontrar patrones.
5. **Evaluación e interpretación:** Analizar la utilidad de los patrones descubiertos.

Modelo CRISP-DM — 6 fases:

1. **Comprensión del negocio:** Definir objetivos.
2. **Comprensión de los datos:** Analizar fuentes y calidad.
3. **Preparación de los datos:** Limpieza y transformación.
4. **Modelado:** Aplicar algoritmos.
5. **Evaluación:** Validar modelos.
6. **Despliegue:** Implementar modelos para uso real.

Ejercicio 1: Repaso de Fundamentos y Procesos

Supongamos que un servicio de streaming quiere reducir la "fuga" de clientes. Para ello, planean usar minería de datos.

1. **Identifica:**
 - ¿Qué tipo de dato podrían recopilar?
 - ¿Qué información podrían derivar de esos datos?
 - ¿Qué conocimiento útil podrían extraer para reducir la fuga?
2. **Relaciona:** Describe brevemente qué acciones de este escenario corresponden a:
 - Fase de Selección de Datos en KDD.
 - Fase de Modelado en CRISP-DM.
 - Fase de Despliegue en CRISP-DM.

Preparación y Análisis Exploratorio de Datos

Antes de aplicar algoritmos, es crucial preparar los datos. La **limpieza de datos** aborda problemas como valores nulos, duplicados e inconsistencias. Las técnicas para manejar datos faltantes incluyen la eliminación de registros o columnas y la imputación (media, mediana, moda o interpolación). La detección de **outliers** también es clave, usando métodos como IQR o boxplots.

La **transformación de datos** incluye normalización, estandarización y codificación de variables categóricas (One-Hot Encoding o Label Encoding).

El **Análisis Exploratorio de Datos (EDA)** involucra:

- **Análisis Univariado:** Examina una variable a la vez (histogramas, boxplots, media, mediana, desviación estándar).
- **Análisis Multivariado:** Analiza relaciones entre dos o más variables (scatter plots, correlación de Pearson, PCA, clustering).

Ejercicio 2: Preparación y EDA Básica

Considera el siguiente conjunto de datos de clientes:

Cliente	Edad	Ingresos	Reclamos	Estado_Cuenta
1	25	50000	1	Pagado
2	40	60000	0	Pagado
3	32	70000	2	Moroso
4	-5	80000	3	Moroso
5	30	45000	0	Pagado
6	45	NaN	2	Pagado

1. Identifica los problemas de calidad en este conjunto de datos (valores faltantes, inconsistentes).
2. Sugiere cómo manejarías estos problemas (eliminar, imputar, corregir).
3. Describe qué tipo de análisis exploratorio realizarías para entender la distribución de "Ingresos" y la relación entre "Edad" e "Ingresos".
¿Qué gráficos usarías?

Técnicas Clave de Análisis: Clustering y Reducción de Dimensionalidad

El **Clustering** es una técnica de aprendizaje no supervisado que busca dividir los datos en grupos homogéneos (clusters) basados en su similitud. Tiene aplicaciones amplias como la segmentación de clientes.

Algoritmos de clustering vistos:

Algoritmo	Descripción	Ventajas / Limitaciones
K-Means	Método particional que divide datos en K clusters basados en la distancia a centroides.	Simple y eficiente; requiere definir K y es sensible a la inicialización.
DBScan	Algoritmo basado en densidad; agrupa puntos próximos y detecta ruido.	Ideal para formas irregulares; no necesita K, pero es sensible a parámetros de densidad.

Algoritmo	Descripción	Ventajas / Limitaciones
SOM (Self-Organizing Maps)	Redes neuronales para visualización y reducción de dimensionalidad, preservando la topología.	Encuentra patrones ocultos; su interpretación puede ser menos intuitiva.

El **Análisis de Componentes Principales (PCA)** se utiliza para la reducción de dimensionalidad. PCA transforma variables correlacionadas en un conjunto más pequeño de componentes principales no correlacionadas, ayudando a reducir variables, facilitar la visualización y mejorar la eficiencia de los modelos. La normalización previa es importante para PCA.

Ejercicio 3: Conceptos de Clustering y PCA

1. Tienes un conjunto de datos de clientes con muchas variables numéricas (edad, ingresos, frecuencia de compra, etc.). ¿Por qué podrías considerar aplicar PCA antes de un análisis de clustering o modelado predictivo?
2. Quieres segmentar a tus clientes en grupos distintos, pero no sabes cuántos grupos existen naturalmente en tus datos. ¿Qué técnica de clustering de las vistas (K-Means, SOM, DBScan) podría ser más adecuada para este caso y por qué?

Visualización de Datos

La visualización de datos es una herramienta fundamental en minería de datos que permite comprender rápidamente grandes volúmenes de información, detectar patrones, identificar valores atípicos y comunicar hallazgos de manera clara.

Tipos de gráficos y cuándo usarlos:

Gráfico	Uso
Histograma	Distribución de una variable numérica.
Boxplot	Detección de valores atípicos y distribución de una variable.
Scatter Plot	Relación entre dos variables numéricas.
Bar Chart	Comparación de categorías.
Line Plot	Evolución en el tiempo.
Heatmap	Correlación entre múltiples variables (matrices de correlación).
Pairplot	Relaciones entre múltiples variables numéricas en un solo gráfico.
Violin Plot	Distribución de datos dentro de cada categoría (mezcla de boxplot e histograma).

Matplotlib vs Seaborn: Matplotlib es más básica y flexible (control total). Seaborn ofrece gráficos estadísticos más atractivos con menos código.

Ejercicio 4: Aplicación de Visualización

Considera el conjunto de datos de clientes corregido (valor faltante de Ingresos en Cliente 6 imputado a 65000; edad inconsistente del Cliente 4 corregida a 35):

Cliente	Edad	Ingresos	Reclamos	Estado_Cuenta
1	25	50000	1	Pagado
2	40	60000	0	Pagado
3	32	70000	2	Moroso
4	35	80000	3	Moroso
5	30	45000	0	Pagado
6	45	65000	2	Pagado

1. ¿Qué tipo de gráfico podrías usar para visualizar la distribución de la variable "Reclamos"?
2. ¿Qué gráfico es ideal para visualizar la relación lineal entre "Edad" e "Ingresos"?

3. Si quisieras ver la correlación entre "Edad", "Ingresos" y "Reclamos" simultáneamente, ¿qué tipo de visualización de Seaborn sería adecuada?

Ejercicio de Repaso Integrador

Estás a cargo de un proyecto de minería de datos para una empresa de telecomunicaciones que busca predecir la probabilidad de que un cliente abandone el servicio (churn). Describe el proceso general que seguirías, haciendo referencia a los conceptos y metodologías vistos en las clases:

- **Etapas de Comprensión (Negocio y Datos):** ¿Qué harías?
- **Etapas de Preparación de Datos:** ¿Qué problemas podrías encontrar y cómo los abordarías?
- **Etapas de Análisis Exploratorio:** ¿Qué buscarías y qué visualizaciones usarías?
- **Etapas de Modelado:** ¿Qué tipo de técnica aplicarías y por qué?
- **Etapas de Evaluación y Despliegue:** ¿Qué implica brevemente?

3. Cierre de la Clase de Repaso

Hemos revisado los pilares de la minería de datos, desde la definición y los procesos estándar hasta las etapas iniciales de preparación, exploración y visualización de datos, y la introducción a técnicas de clustering y PCA. Recordemos la importancia de la calidad de los datos y de visualizar para comprender y comunicar hallazgos. Las metodologías KDD y CRISP-DM ofrecen un marco sólido para abordar los proyectos de manera estructurada.

Bibliografía

1. Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques* (3rd ed.). Elsevier.
2. Hernández Orallo, J., Ramírez Quintana, M. J., & Ferri Ramírez, C. (2004). *Introducción a la Minería de Datos*. Pearson-Prentice Hall.
3. Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2017). *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann.
4. Layton, R. (2017). *Learning Data Mining with Python* (2nd ed.). Packt Publishing.
5. Scikit-learn Developers. (n.d.). Recuperado de <https://scikit-learn.org/>
6. Seaborn Documentation. (n.d.). Recuperado de <https://seaborn.pydata.org/>
7. Matplotlib Developers. (n.d.). Recuperado de <https://matplotlib.org/>